

Mask R-CNN İle Uydu Görüntülerinde Gemi Tespiti

1. Giriş

Gemi tespiti, ülke karasularının gözetimi, güvenliği, yönetimi ve deniz taşımacılığı gibi birçok alanda kritik bir rol oynamaktadır. Bu süreç, uydu veya hava fotoğraflarında gemilerin tespit edilmesini ve konumlarının belirlenmesini içerir. Son yıllarda, yüksek çözünürlüklü uydu görüntülerinin artması ve yeni algılama modellerinin geliştirilmesi, gemilerin otomatik olarak tespit edilmesini mümkün kılmıştır.

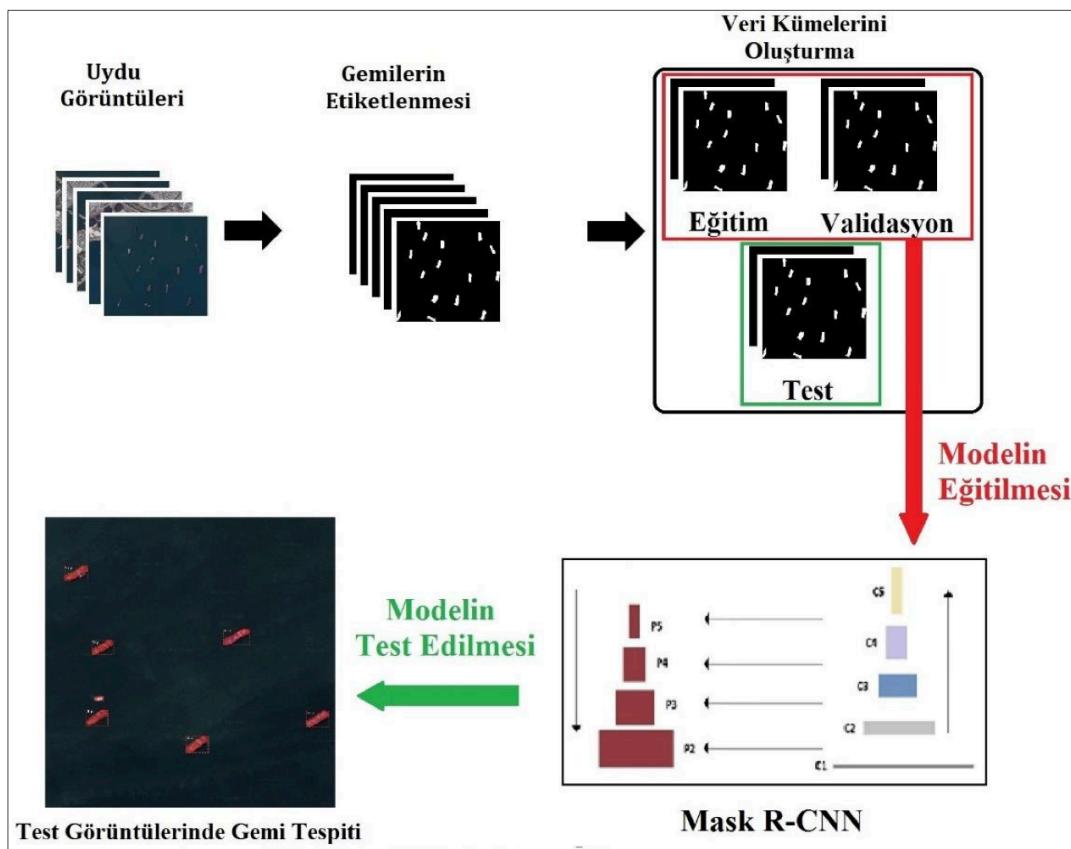
Makine öğrenimi, özellikle de derin öğrenme yöntemleri, bu alanda büyük bir ilerleme sağlamıştır. Geleneksel makine öğrenimi yöntemleri (örneğin, SVM) bazı durumlarda performans düşüşü yaşayabilirken, konvolüsyonel sinir ağları (CNN) gibi derin öğrenme modelleri, nesne tespiti ve sınıflandırma görevlerinde daha başarılı sonuçlar vermiştir. Ancak, nesnenin görüntüyü tam olarak kaplamadığı durumlarda, CNN'lerin uyarlanması gerekmektedir.

Bu sorunu çözmek için, özellikle iki farklı yaklaşım öne çıkmıştır; bölge-tabanlı CNN yaklaşımları (örneğin, Faster R-CNN ve Mask R-CNN) ve bölge öneri ağına ihtiyaç duymayan yöntemler (örneğin, YOLO ve SSD). Mask R-CNN, nesne tespiti ve konumlandırma görevlerinde etkili bir şekilde kullanılan bir modeldir. Bu model, görüntülerdeki nesneleri sınırlayıcı kutular ve maskelerle işaretleyerek, nesnelerin kesin konumlarını ve şekillerini belirlemeyi mümkün kılar.

Bu çalışmada, Mask R-CNN'in uydu görüntülerinde gemi tespiti üzerindeki performansı incelenecaktır. Modelin eğitimi için maskelerle etiketlenmiş veri setleri oluşturulacak ve en uygun parametreler belirlenecektir. Son olarak, çeşitli metriklerle modelin başarı düzeyi değerlendirilerek avantajları ve dezavantajları tartışılacaktır.

2. Materyal ve Yöntem

Bu çalışmada, uydu görüntülerinde gemi tespiti için Şekil-1'de gösterilen belirli bir akış süreci izlenmiştir. Süreç ham görüntülerle başlamakta, görüntü işleme ve etiketleme adımlarıyla devam etmekte ve nihayetinde model eğitimi ve test işlemleriyle sonlandırılmaktadır.



Şekil 1. Çalışmadaki Gemi Tespit Prosedürü

2.1 Veri Setleri

Veriler, Google Earth tarafından sağlanan 1 metre mekânsal çözünürlüklü, RGB formatındaki uydu görüntülerinden oluşmaktadır. Bu görüntüler, açık denizler, kıyı yakınları ve iç sular gibi farklı bölgelerden örnekler içermektedir.

Toplamda 1838 adet görüntü, her biri 768x768 piksel boyutunda olacak şekilde hazırlanmıştır. Bu görüntüler, eğitim, validasyon ve test veri setleri olarak ayrılmıştır. Görüntülerdeki toplam 3279 gemi, bir GIS yazılımı kullanılarak sayısallaştırılmıştır. Bu işlem, gemilerin görüntülerdeki konumlarının ve sınırlarının belirlenmesini sağlamıştır.

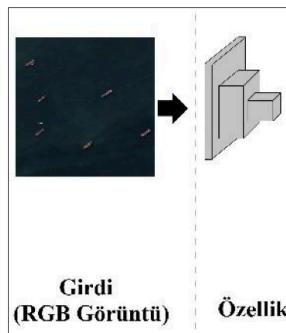
Eğitim ve validasyon setleri, modelin eğitilmesi ve doğrulanması için kullanılmıştır. Daha sonra, eğitilen model, test görüntülerini üzerinde çalıştırılarak tespit performansı hesaplanmıştır. Bu süreç, modelin gemi tespiti yeteneğini değerlendirmek için kullanılmıştır.

Tablo 1. Çalışma Kapsamında Kullanılan Veri Kümelerine Dair Bilgiler

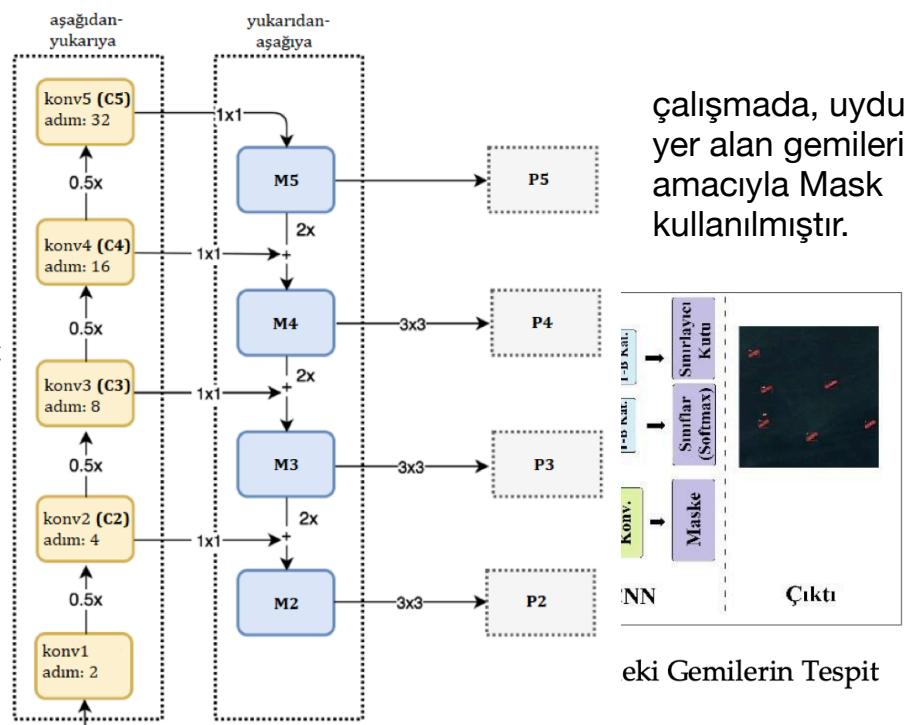
	Eğitim Kümesi	Validasyon Kümesi	Test Kümesi	Toplam
Görüntü Sayısı	1224	320	294	1838
Gemi Sayısı	2096	579	604	3279

2.2. Yöntem

Bu görüntülerinde tespit etmek R-CNN modeli



Şekil 2. Bir Girdi Gö:



çalışmada, uydu yer alan gemileri amacıyla Mask kullanılmıştır.

eki Gemilerin Tespit

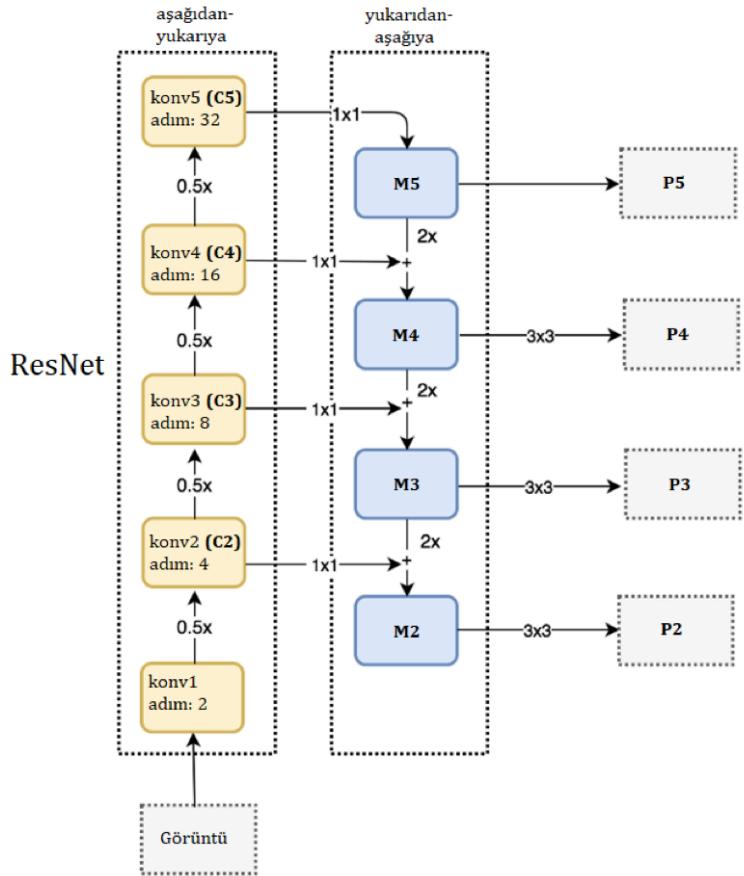
Model, giriş Şekil-2'deki geçirerek işleyip gemilerin maskelerini, sınırlayıcı kutularını ve her tespitin olasılık değerini üretmektedir.

Model, dört ana modülden oluşmaktadır: özellik çıkarım ağı, bölge öneri ağı (RPN), öneri işleme modülü ve bölge-tabanlı konvolüsyonel sinir ağı (R-CNN).

görüntüsünü aşamalardan çıktı olarak

1. Özellik Çıkarım Ağı:

- Girdi görüntüsü, **konvolüsyonel katmanlar** aracılığıyla işlenerek özellik haritalarına dönüştürülür. Bu süreçte, görüntünün mekânsal boyutları küçülürken, derinliği (semantik bilgi) artar.
- Bu çalışmada, **Özellik Piramit Ağı (FPN)** kullanılmıştır. FPN, yüksek çözünürlüklü ancak sığ semantik bilgiye sahip katmanları, derin katmanlardaki semantik bilgiyle birleştirir. Bu sayede farklı ölçeklerdeki nesnelerin tespiti kolaylaşır.
- FPN, **aşağıdan yukarıya** ve **yukarıdan aşağıya** olmak üzere iki yol izler:
- Aşağıdan yukarıya yol:** Görüntü, 5 ayrı blokta işlenerek özellik haritaları (C1, C2, C3, C4, C5) üretilir. Bu haritaların mekânsal boyutları giderek küçülürken, derinliği (semantik bilgi) artar.
- Yukarıdan aşağıya yol:** C5 haritası 1x1'lik konvolüsyon filtresiyle işlenerek M5 haritası oluşturulur. Daha sonra, **en yakın komşuluk üst-örneklemesi** yöntemiyle M5'in mekânsal çözünürlüğü artırılır ve alt katmanlardaki özellik haritalarıyla birleştirilir. Bu işlem, P5, P4, P3 ve P2 özellik haritalarını oluşturur.
- Her bir özellik haritası (P2, P3, P4, P5), aynı derinliğe ($d=256$) sahiptir. Bu, R-CNN modülünde kullanılacak sınıflandırıcı ve kutu regresörünün tutarlığını sağlar.



2. Bölge Öneri Ağı (RPN):

- RPN, görüntüde nesne olma olasılığı yüksek bölgeleri (sınırlayıcı kutular) önerir. Bu öneriler, **çapalar (anchors)** kullanılarak oluşturulur.
- RPN, özellik haritalarında çapalar oluşturur ve bu çapalar üzerinde iki paralel konvolüsyon işlemi gerçekleştirir:
- Sınıflandırma:** Çapanın bir nesne içerip içermediğini belirler.
- Regresyon:** Çapanın konumunu, gerçek nesneye daha iyi oturacak şekilde düzeltir.
- Önerilen bölgeler, bir **güven eşiğine** göre "gemi" veya "arka plan" olarak sınıflandırılır. Güven eşiği, önerinin nesne olma olasılığını belirler. Bu eşik, deneylerle belirlenir.
- Önerilen bölgeler, nesnenin boyutuna göre uygun ölçekteki özellik haritasından çıkarılır. Bu seçim, bir denklem kullanılarak yapılır. Örneğin, küçük nesneler için daha büyük ölçekli haritalar (P2 gibi), büyük nesneler için daha küçük ölçekli haritalar (P5 gibi) kullanılır.

3. Öneri İşleme Modülü (Röl Hızalama):

- RPN tarafından önerilen bölgeler, **Röl Hızalama** işlemiyle standart bir boyuta getirilir. Bu işlem, önerilen bölgelerin konvolüsyonel özellik haritalarından hizalanarak kırılmasını ve **bilineer enterpolasyon** ile 14x14 boyutuna getirilmesini içerir.
- Daha sonra, **max-pooling** işlemiyle bu bölgeler 7x7 boyutuna indirgenir. Bu adım, tam-bağlantılı katmanların kullanılabilmesi için gereklidir.

- Rol Hızalama, önerilerin doğruluğunu artırarak modelin performansını iyileştirir. Orijinal çalışmada, Rol Hızalamanın doğruluğu Rol Havuzlamasına göre %20'ye varan oranda daha iyi sonuçlar verdiği belirtilmiştir.

4. Bölge-Tabanlı Konvolüsyonel Sinir Ağı (R-CNN):

- Bu modül, RPN önerilerini işleyerek gemilerin sınıflandırılmasını, sınırlayıcı kutuların düzeltmesini ve maskelerin oluşturulmasını sağlar.
- **Tam-bağlantılı katmanlar**, önerilen bölgeleri sınıflandırır ve sınırlayıcı kutuların konumlarını düzeltir. Ayrıca, her gemi için bir maske oluşturulur.
- Maskeler, objenin görünür dış hatlarına uygun şekilde çizilen bir poligondur ve nesnenin kesin sınırlarını belirler.

2.3. Model Eğitimi

Bu çalışmada, Mask R-CNN modeli için Waleed'in (2017) TensorFlow ve Keras uyarlaması kullanılmıştır. COCO veri setiyle ön-eğitim almış ResNet-101, modelin omurga ağı olarak seçilmiştir.

Model, 2'si RPN, 3'ü R-CNN olmak üzere toplam 5 kayıp fonksiyonu ile 80.000 iterasyon boyunca eğitilmiştir. Öğrenme oranı 0,001, ağırlık bozunu 0,0001, momentum katsayı 0,9 olarak belirlenmiş ve Momentumlu Stokastik Gradyan İniş (SGD-Momentum) ile optimize edilmiştir.

Deneyler, Intel i7-6850k işlemci, 64 GB RAM ve Nvidia GTX 1080 Ti GPU kullanan bir Ubuntu 16.04 sisteminde gerçekleştirilmiştir.

2.4. Tespit Değerlendirme Metrikleri

Modelin tespit performansı, kesinlik (precision), geri getirme (recall) ve F1-skora dayalı olarak değerlendirilmiştir. Bu metrikler, yalnızca doğru tespitleri (True Positives - TP) değil, aynı zamanda yanlış alarmları (False Positives - FP) ve gözden kaçan nesneleri (False Negatives - FN) de dikkate alarak performans ölçümü sağlar.

- **Kesinlik (Precision)**: Doğru tahminlerin toplam tahminler içindeki oranını gösterir ($TP / (TP + FP)$). Yanlış alarmların etkisini değerlendirmek için kullanılır.
- **Geri Getirme (Recall)**: Doğru pozitiflerin toplam yer doğruluklarına oranıdır ($TP / (TP + FN)$) ve modelin hedeflenen nesneleri ne oranda tespit ettiğini ölçer.
- **F1-Skoru**: Kesinlik ve geri getirmenin harmonik ortalaması olup, modelin genel tespit performansını değerlendirir ($2TP / (2TP + FN + FP)$).

Çalışmada, bir tespit tahmininin **gerçek doğru (TP) sayılması için IoU (Intersection over Union) değeri 0,5'ten büyük** olmalıdır. Aksi takdirde, tahmin yanlış tespit (FP) olarak değerlendirilmiştir.

3. Bulgular ve Tartışma

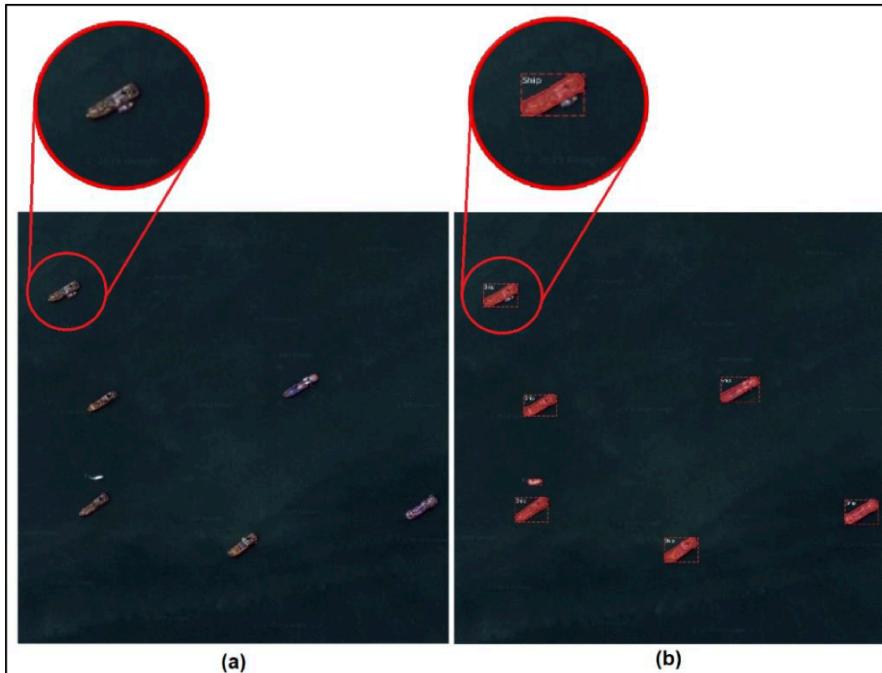
Çalışmada, modelin en uygun güven eşliğini belirlemek amacıyla deneyler yapılmıştır. Güven eşiği 0'dan 1'e kadar 0,1'lik adımlarla artırılmış ve her adım için tespit metrikleri hesaplanmıştır. Optimal eşik değeri 0,5 olarak belirlenmiş ve bu değerle doğru tespitler ile yanlış alarmlar arasında en iyi denge sağlanmıştır.

Seçilen 0,5 eşik değeriyle model, test kümelerindeki 604 nesneden 558'ini doğru tespit etmiş, 46'sını gözden kaçırılmış ve 58 yanlış alarm üretmiştir. Bu doğrultuda modelin başarı metrikleri şu şekilde hesaplanmıştır:

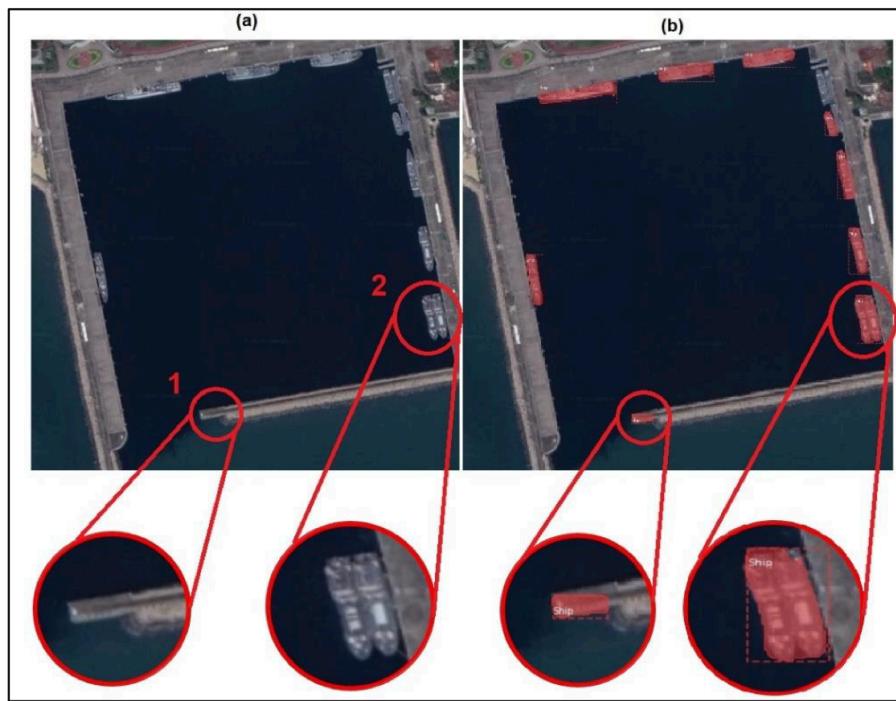
- **Geri getirme oranı (recall):** 0,9238
- **Kesinlik (precision):** 0,9058
- **F1-Skoru:** 0,9148

Model, ResNet-101 omurga ağı ile çalıştırılarak test görüntülerü üzerinde değerlendirilmiştir:

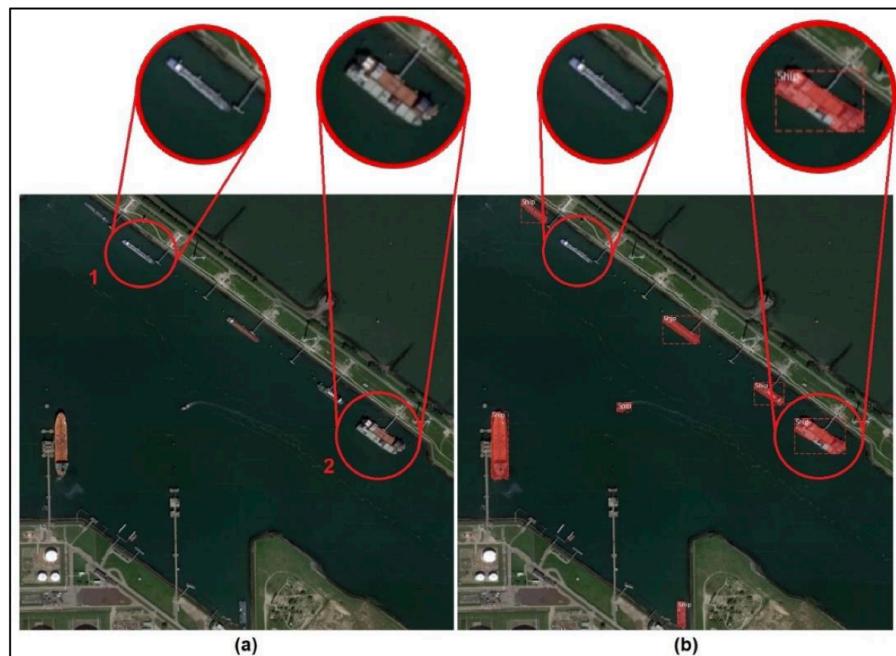
- **Şekil 4 (Singapur Limanı):** 8 gemiden 7'si doğru tespit edilmiş, küçük bir gemi gözden kaçırılmıştır.
- **Şekil 5 (Hong Kong Askeri Limanı):** 10 gemiden 8'i doğru tespit edilmiş,
 - Model, bir kara parçasını yanlışlıkla gemi olarak sınıflandırmış.
 - Yan yana duran iki gemiyi tek bir gemi olarak işaretlemiştir.
 - Bir gemiyi gözden kaçırılmıştır.
- **Şekil 6 (Rotterdam İç Limanı):** 9 gemiden 7'si doğru tespit edilmiş,
 - Limana yanaşmış bir gemi tespit edilememiştir.
 - Yan yana duran iki gemi tek bir nesne olarak algılanmıştır.



Şekil 4. Açık Denizde Bulunan Gemileri İçeren Bir Uydu Görüntüsü (a) ve Modelin Bu Görüntü İçin Ürettiği Tespit Sonucu (b)



Şekil 5.Hong Kong'daki Askeri Bir Limana Yanaşmış Gemileri İçeren Bir Uydu Görüntüsü (a) ve Modelin Bu Görüntü İçin Ürettığı Tespit Sonucu (b)



Şekil 6.Rotterdam'daki Bir İç Limanda Bulunan Gemileri İçeren Bir Uydu Görüntüsü (a) ve Modelin Bu Görüntü İçin Ürettği Tespit Sonucu (b)

Modelin, birbirine yakın nesneleri ayırt etmede zorlandığı gözlemlenmiştir. Bu durum, Faster R-CNN gibi bölge tabanlı nesne tespit algoritmalarında da karşılaşılan bir problemdir. Problemin, RPN'de (Bölge Öneri Ağı) kullanılan dikdörtgen sınırlayıcı kutulardan kaynaklandığı ifade edilmiştir. Çözüm olarak, döndürülmüş sınırlayıcı kutuların kullanılması önerilmektedir. Faster R-CNN üzerine inşa edilen Mask R-CNN için de bu tartışma geçerlidir.

4. Sonuç

Bu çalışmada, bölge tabanlı Mask R-CNN modeli kullanılarak uydu görüntülerinde gemi tespiti gerçekleştirilmiş ve modelin performansı çeşitli metriklerle değerlendirilmiştir. Mask R-CNN'nin diğer yöntemlerden farkı, gemileri yalnızca sınırlayıcı kutularla değil, aynı zamanda maskelerle işaretleyerek daha detaylı tespit yapabilmesidir.

Deneysel sonucunda, 0,5 güven eşiği ile modelin 604 gemiden 558'ini doğru tespit ettiği ve 58 yanlış alarm ürettiği belirlenmiştir. Modelin tespitleri incelediğinde:

- Birbirine yakın konumlanmış gemileri tek bir nesne olarak algılama eğiliminde olduğu veya bazı gemileri gözden kaçırıldığı gözlemlenmiştir.
- Bazı karasal bölgelerin yanlışlıkla gemi olarak sınıflandırıldığı ve karaya yanaşmış bazı gemilerin tespit edilemediği durumlar ortaya çıkmıştır.

Gelecek çalışmalarında, bu hata türlerinin nedenlerini belirlemek ve modelin doğruluğunu artırmak amacıyla yeni deneyler yapılması planlanmaktadır. Ayrıca, Mask R-CNN'nin performansının diğer nesne tespit modelleriyle karşılaştırılması da hedeflenmektedir.

GEMİ TESPİTİ UYGULAMASINDA YOLOV8 VE YOLOV9 ALGORİTMALARININ PERFORMANS DEĞERLENDİRMESİ

1. Giriş

Geleneksel yöntemlerle yapılan nesne tespiti, insan hatalarına, zaman kaybına ve yüksek maliyetlere yol açtığından, bilgisayarlı görme ve makine öğrenmesi yöntemleri bu sorunların çözümünde kritik bir rol oynamaktadır. Gemi tespiti, hem sivil hem de askeri alanlarda büyük bir öneme sahiptir; balıkçılık yönetimi, deniz trafiği kontrolü, yasadışı göçmen takibi ve askeri stratejilerde aktif olarak kullanılmaktadır.

Makale, uzaktan algılama teknolojilerinin, gemi tespitinde önemli bir araç haline geldiğini vurgulamaktadır. Uydu ve hava araçlarına monte edilen sensörler

sayesinde, uzun mesafeden yüksek çözünürlüklü görüntüler elde edilerek, coğrafi kısıtlamalar olmadan gemi hareketleri izlenebilmektedir. Ancak, gemi tespiti süreci hâlâ zorluklarla doludur. Karmaşık deniz ortamları, gemilerin büyük ölçekli varyasyonları, yoğun dağılımlar ve görüntülerde pozitif-negatif örnek dengesizliği gibi faktörler, mevcut modellerin performansını sınırlamaktadır.

Geleneksel CNN ve Transformer tabanlı yöntemler incelendiğinde, gemi tespiti çalışmalarının diğer nesne tespit araştırmalarının gerisinde kaldığı belirtilmektedir. Son yıllarda YOLO mimarisi, hızlı ve doğru sonuçlar üretmesi nedeniyle gemi tespitinde sıkça kullanılan bir yöntem haline gelmiştir. YOLO tabanlı modeller, özellikle deniz ortamlarındaki karmaşıklıklarla başa çıkabilmek adına çeşitli iyileştirmelerle geliştirilmiştir. Örneğin, SAR-LtYOLOv8 modeli küçük nesneleri daha iyi algılayabilmesi için optimize edilmiş, Ship-Fire Net ise gemi yangınlarını tespit etmek için özel olarak tasarlanmıştır. Ayrıca, aktif kontur tabanlı YOLOv8 modelleri, SAR görüntülerinde gemi tespiti ve sınıflandırmada başarılı sonuçlar vermektedir.

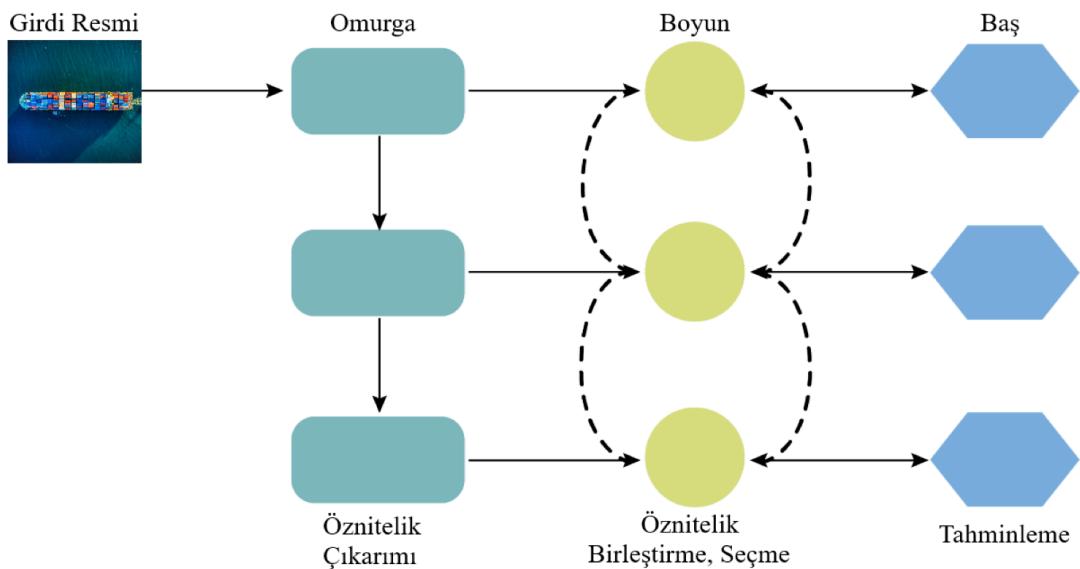
Bu çalışma, YOLO mimarisinin en yeni versiyonları olan YOLOv8 ve YOLOv9'un uzaktan algılama ile gemi tespitindeki performansını değerlendirmeyi amaçlamaktadır. Makalenin ikinci bölümünde kullanılan veri setleri ve yöntemler açıklanırken, üçüncü bölümde deneysel sonuçlar ele alınmakta, dördüncü bölümde ise sonuçlar değerlendirilmektedir.

2. Materyal ve Metot

2.1. YOLO Algoritması

YOLO (You Only Look Once) algoritması, nesne tespiti için hesaplama karmaşıklığını azaltan birlesik bir model olarak geliştirilmiştir. YOLO, görüntüyü doğrudan giriş olarak kullanarak tek bir regresyon problemi şeklinde nesne tespiti gerçekleştirir. Model, sınırlayıcı kutu koordinatlarını ve sınıf olasılıklarını doğrudan çıkış katmanında döndürerek hızlı ve verimli bir nesne algılama süreci sunar. Bu özelliği sayesinde gerçek zamanlı nesne tespiti için önemli bir gelişme sağlamıştır. YOLO mimarisi üç temel bileşenden oluşur:

- Omurga (Backbone):** Görüntüdeki öznitelikleri çıkarmak için kullanılan temel katmandır.
- Boyun (Neck):** Özniteliklerin birleştirilmesi ve önemli olanların seçilmesini sağlar.
- Baş (Head):** Son tahminleri yaparak nesnelerin konumlarını ve sınıflarını belirler.



Şekil 2. YOLO Mimarisinin Bölümleri (Parts of YOLO Architecture) [21]

YOLO algoritması, yıllar içinde geliştirilerek farklı sürümleri yayımlanmıştır:

- **YOLOv2 (YOLO9000, 2016):** Batch normalization kullanılarak eğitim süresi kısaltılmış ve doğruluk artırılmıştır. Darknet-19 mimarisi ile daha fazla nesne sınıfını algılayabilen bir yapı sunulmuştur.
- **YOLOv3 (2018):** Darknet-53 mimarisi ile çoklu ölçeklerde nesne tespiti geliştirilmiş ve küçük nesneler için tespit performansı iyileştirilmiştir.
- **YOLOv4 (2020):** CSPDarknet53 mimarisi, mozaik veri arttırma, CIOU kaybı ve SAM bloğu gibi yenilikçi teknikler eklenerek hız ve doğruluk daha da iyileştirilmiştir.
- **YOLOv5 (2020):** Ultralytics tarafından PyTorch tabanlı olarak geliştirilmiş, eğitim sürecini basitleştiren hafif ve hızlı bir modeldir.
- **YOLOv6 (2022):** PyTorch tabanlı olarak geliştirilmiş ve YOLOv5'e alternatif bir model olarak optimize edilmiştir.
- **YOLOv7 (2022):** Gerçek zamanlı nesne tespiti için optimize edilerek hız ve doğruluk açısından yüksek performans sunmuştur.
- **YOLOv8 (2023):** Önceki modellerden farklı olarak hız, doğruluk ve kullanım kolaylığı açısından önemli geliştirmeler içermektedir.
- **YOLOv9 (2024):** Derin sinir ağı tabanlı olarak geliştirilmiş en yeni nesil YOLO sürümüdür ve nesne algılama doğruluğunu artıran yenilikçi yaklaşımalar sunmaktadır.

YOLO mimarisinin sunduğu hız ve doğruluk avantajları sayesinde, gemi tespiti gibi uzaktan algılama ve gerçek zamanlı izleme gerektiren birçok uygulamada kullanımı yaygınlaşmıştır.

2.2. YOLOv8 Algoritması

YOLOv8, mimari iyileştirmeler, gelişmiş kayıp fonksiyonları ve segmentasyon yetenekleri ile YOLO serisinde önemli bir ilerleme sağlamıştır. En büyük yeniliği, C2f

(Cross Stage Partial) modülü olup, bu modül gradyan akışını iyileştirerek modelin öğrenme sürecini hızlandırmakta ve daha verimli hale getirmektedir.

C2f modülü, katmanlar arasındaki bilgi kaybını minimize eder, geri yayılımı optimize eder ve Non-Maximum Suppression (NMS) sürecini hızlandırarak daha doğru ve hızlı nesne tespiti sağlar. Bu geliştirmeler sayesinde YOLOv8, gerçek zamanlı nesne tespiti ve görüntü segmentasyonu gibi alanlarda yüksek performans sunan güçlü bir model olarak öne çıkmaktadır.

2.3. YOLOv9 Algoritması

YOLOv9, omurga ağında CSPDarknet53 kullanarak giriş görüntüsünden öznitelikleri çıkarmakta ve gradyan kaybolmasını önlemek için artık (residual) bir yapı benimsemektedir. Omurga, derin ve hafif evrişimsel katmanlardan oluşan iki ayrı bölüme ayrılarak öznitelik gösterimini güçlendirmektedir.

Özellik birleştirme ağı, Mekansal Piramit Havuzlama (SPP) ve Yol Toplama Ağı (PAN) modüllerini kullanarak farklı ölçeklerdeki özellik haritalarını entegre eder. Ayrıca, YOLOv5'ten CSP Bloğu, YOLOv6'dan RepVGGBlock ve YOLOv7'den ELAN Bloğu alınarak RepNCSPELAN4 modülü oluşturulmuştur. Bu yapı, modelin öğrenme kapasitesini artırarak daha karmaşık nesne tespiti görevlerinde daha yüksek doğruluk oranları elde etmesini sağlamaktadır.

2.4. Veri Seti

Bu çalışmada, "Ships in Google Earth" veri seti kullanılmış olup, veri seti Kaggle'da barındırılan ve Roboflow tarafından kullanıma sunulan bir uydu görüntü koleksiyonudur. Toplamda 1658 görüntünden oluşan veri seti, farklı hava koşulları, ışık seviyeleri (gece-gündüz) ve çeşitli tip ve uzunluklardaki gemileri içermektedir.

Veri kümesi, üç gruba ayrılmıştır:

- **Eğitim seti:** %86'lık bir payla 1420 görüntü,
- **Doğrulama seti:** %10'luk bir payla 159 görüntü,
- **Test seti:** %5'lük bir payla 79 görüntü.

Görüntüler genellikle 30-50 cm çözünürlüğe sahiptir ve gemiler çoğunlukla boş okyanus arka planı üzerinde görülmektedir, ancak bazı görüntüler sahil şeridine yakın veya küme halinde gemileri içerebilir.

Veri ön işleme süreci şu adımları içermektedir:

1. Otomatik yönlendirme (Auto-Orient) uygulanarak görüntülerin hizalanması,
2. 640x640 piksel boyutuna ölçeklendirme.

Veri artırma (augmentation) sürecinde:

- Görüntüler yatay olarak çevrilmiş (Flip: Horizontal),

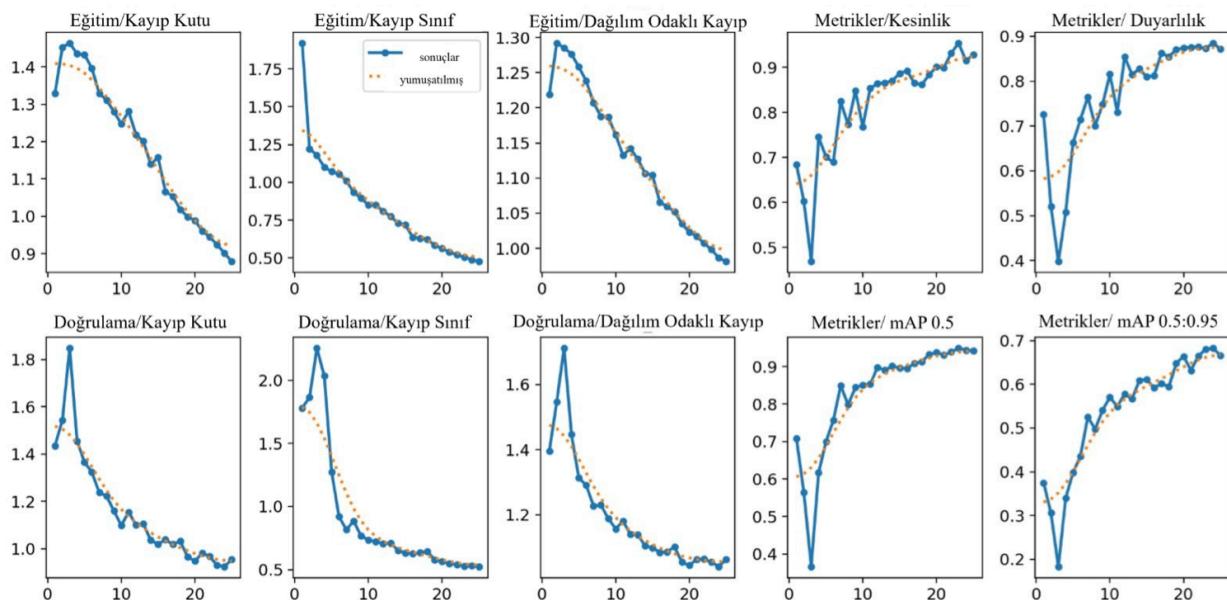
- 90° saat yönünde ve saat yönünün tersine döndürülmüştür (Clockwise & Counter-Clockwise).

Ayrıca, tüm gemiler sınırlayıcı kutular (bounding box) ile etiketlenmiş ve YOLOv5 gibi modeller için uygun hale getirilmiştir.

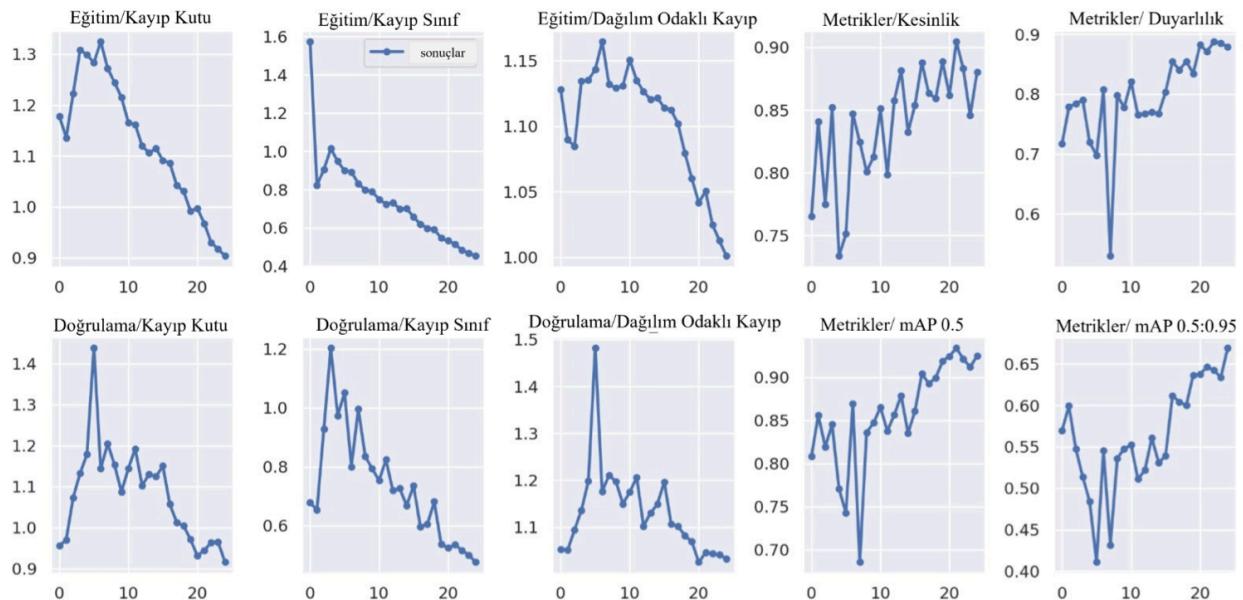
3. Araştırma Bulguları

Çalışmada YOLOv8 ve YOLOv9 modelleri 25 iterasyon boyunca eğitilmiş ve batch_size değeri 16 olarak belirlenmiştir. Eğitim süreci, kesinlik ($TP/TP+FP$), duyarlılık ($TP/TP+FN$) ve ortalama hassasiyet metriklerine göre değerlendirilmiştir.

YOLOv8 ve YOLOv9 modellerinin eğitim süreçleri boyunca elde edilen eğitim metrik değerlerinin değişimini gösteren grafikler Şekil 3 ve Şekil 4'te sunulmaktadır.



Şekil 3. YOLOv8 Eğitim Metrikleri (YOLOv8 Training Metrics)



Şekil 4. YOLOv9 Eğitim Metrikleri (YOLOv9 Training Metrics)

Sonuçlar ve Karşılaştırmalar

- **Eğitim Kaybı:** İterasyon arttıkça her iki modelde de azalma eğilimi gözlenmiştir. YOLOv8'in kayıp eğrileri daha stabil, YOLOv9'un ise hızlı yakınsadığı tespit edilmiştir.
- **Doğrulama Kaybı:** Zamanla azalmış ancak daha fazla dalgalanma göstermiştir. YOLOv9'un doğrulama kayipları daha düşük, bu da daha iyi genelleme performansı sunduğunu gösterir.
- **Kesinlik ve Duyarlılık:** YOLOv9, eğitimin başlarında daha yüksek değerlere ulaşmış, ancak YOLOv8 zamanla benzer seviyelere gelmiştir.
- **mAP Değerleri:** YOLOv9, mAP@0.5:0.95 açısından daha iyi performans göstermiştir. Küçük ve gizli nesneleri tespitte ufak bir üstünlüğü bulunmaktadır.

Genel olarak YOLOv9, daha hızlı öğrenme ve daha iyi genelleme performansı sergilemiştir, ancak her iki modelde dalgalanmalar gözlendiği için veri artırımı veya düzenleme gerekebilir.

4. Tartışma ve Sonuç

Çalışmada YOLOv8 ve YOLOv9, gemi tespiti uygulaması için incelenmiştir. Her iki model de nesne tespiti ve görüntü segmentasyonu alanında güçlü performans sergileyen YOLO ailesine aittir.

Sonuçlar ve Değerlendirme

- YOLOv9, YOLOv8'e kıyasla mAP ve duyarlılık açısından daha iyi performans göstermiştir.

- YOLOv9'un erken iterasyonlarda hızlı yakınsaması, daha az iterasyonla bile yüksek başarı sağlayabileceğini göstermektedir.
- Eğer tespit kalitesi öncelikliyse, YOLOv9 daha uygun bir seçenek olabilir. Ancak, seçim sürecinde çıkarsama hızı ve hesaplama verimliliği de göz önünde bulundurulmalıdır.
- YOLOv8 ise daha geniş bir uygulama alanına sahip olup, farklı veri setlerinde kullanılabilir.
- Her iki model de gemi tespiti için etkili çözümler sunmuştur, ancak seçim, uygulamanın özgül gereksinimlerine ve donanım kaynaklarına bağlıdır.

Gelecek Çalışmalar

- Çalışma, gemi örneklerinden oluşan veri seti ile başarıyla tamamlanmıştır.
- Literatürde, YOLO modellerinin farklı veri setleri üzerinde de başarılı sonuçlar verdiği gösterilmiştir.
- Gelecekteki çalışmalar, yalnızca gemi türlerini değil, diğer deniz araçlarını da içeren geniş kapsamlı veri setleriyle yapılabilir.
- YOLO mimarilerinin sürekli gelişimiyle birlikte, en güncel versiyonlarının kullanımı daha başarılı sonuçlar verebilir.

Genel olarak YOLOv9'un tespit kalitesi ve verimliliği, onu gemi tespiti için daha cazip bir seçenek haline getirse de, model seçimi uygulamanın gereksinimlerine bağlıdır.

GELİŞMİŞ DENİZ GÖZLEMI: SAR TABANLI GEMİ TESPİTİ İÇİN CNN ALGORİTMALARININ KULLANIMI

1. Giriş

Gemi tespiti, denizcilik sektöründe güvenlik, trafik yönetimi, çevresel izleme ve arama kurtarma gibi birçok alanda kritik bir rol oynamaktadır. Gerçek zamanlı gemi tespiti, gemi hareketleri hakkında önemli bilgiler sağlayarak, yetkililerin korsanlık ve kaçakçılık gibi tehditleri izlemesine, liman trafiğini daha etkin yönetmesine ve çevresel kirliliği takip etmesine yardımcı olmaktadır.

Son yıllarda, uydu ve radar görüntüleme teknolojilerindeki ilerlemeler ile birlikte derin öğrenme algoritmalarının gelişimi, gemi tespiti ve takibini daha etkili hale getirmiştir. Özellikle konvolüsyonel sinir ağları (CNN) ve tekrarlayan sinir ağları (RNN) gibi yapay zeka tabanlı teknikler, uydu verilerinden nesne tespiti konusunda yüksek doğruluk oranları elde edilmesini sağlamaktadır. Çeşitli çalışmalarda, CNN tabanlı modellerin kentsel alanlardaki binaları, okyanus üzerindeki gemileri ve tarımsal alanlardaki mahsulleri tespit etmede başarılı sonuçlar verdiği gösterilmiştir. Ancak, uydu verilerinin kalitesi ve derin öğrenme modellerinin büyük ölçekli veri kümeleri üzerinde eğitilmesinin getirdiği zorluklar, bu alandaki gelişmelerin önünden önemli engeller olarak durmaktadır.

Faster R-CNN, nesne algılama alanında yaygın olarak kullanılan bir derin öğrenme algoritması olup, iki ana bileşenden oluşmaktadır: Bölge Öneri Ağı (RPN) ve Algılama Ağı. Bu modelin, gemi tespiti, trafik yönetimi ve otonom sistemler gibi birçok farklı alanda başarılı sonuçlar verdiği bilinmektedir. Faster R-CNN'nin başarısını artırmak için çeşitli geliştirmeler yapılmış ve SAR (Sentetik Açıklıklı Radar) görüntüler üzerinde de etkin bir şekilde kullanıldığı gösterilmiştir.

SAR görüntüleri, hava koşullarından ve ışık seviyelerinden bağımsız olarak deniz yüzeyinin yüksek çözünürlüklü görüntülerini sağlayarak, gemi tespiti için güçlü bir araç sunmaktadır. SAR verileriyle yapılan gemi tespiti çalışmaları, geleneksel istatistiksel ve matematiksel yöntemlerden makine öğrenmesi tabanlı modellere kadar çeşitli yaklaşımalar içermektedir. Son yıllarda, CNN tabanlı modellerin SAR görüntülerinde umut verici sonuçlar verdiği görülmüştür. Ancak, deniz ortamının dinamik yapısı ve gemi özelliklerindeki değişkenlikler, bu alanda daha fazla araştırmaya ihtiyaç duyulduğunu göstermektedir.

Bu çalışmada, SAR görüntüleri kullanılarak gemi tespiti için Faster R-CNN tabanlı bir algoritma önerilmiştir. Araştırmada Sentinel-1 VH uydu verileri kullanılarak açık kaynaklı bir veri kümlesi üzerinde modelin başarımı test edilmiş ve %86,11 doğruluk oranına ulaşıldığı gösterilmiştir. Çalışmanın ilerleyen bölümlerinde, önerilen metodolojinin detayları, deneyel sonuçlar ve performans değerlendirmeleri sunulmaktadır.

2. Materyal ve Yöntem

2.1. Çalışma Alanı

Mersin Limanı, Akdeniz'in doğu kıyısında yer alan ve Türkiye'nin en büyük ve en önemli limanlarından biridir. Tarihi Roma dönemine kadar uzanan bu liman, günümüzde Türkiye'nin uluslararası ticaretinde kilit bir rol oynamaktadır. Avrupa, Orta Doğu ve Asya pazarlarına erişim sağlayarak hem ihracat hem de ithalat için kritik bir geçit görevi görmektedir. Modern altyapısıyla dikkat çeken liman; derin su limanı, ileri teknolojiye sahip konteyner terminalleri ve gelişmiş lojistik tesisleri ile donatılmıştır. Stratejik konumu ve bu gelişmiş altyapı unsurları sayesinde küresel ticaretin önemli merkezlerinden biri haline gelmiştir. Aynı zamanda, Mersin bölgesinin ekonomik kalkınmasına katkı sağlamaktır, istihdam yaratmakta ve yerel ekonomiyi desteklemektedir.



Şekil 1. Çalışma Alanı.

2.2. Veri

Sentinel-1, Avrupa Uzay Ajansı (ESA) tarafından yer gözlem uygulamaları için geliştirilen bir radar uydu görevidir. Sentetik Açıkkılık Radar (SAR) teknolojisine sahip olup, farklı polarizasyon modlarında veri sağlayabilir. Özellikle dikey gönderme ve yatay alma (VH) polarizasyonu, arazi örtüsü sınıflandırması, orman haritalama ve gemi tespiti gibi çeşitli uygulamalarda kullanılmaktadır. VH polarizasyonu, küçük ve karmaşık geometrilere sahip balıkçı tekneleri ve mavnalar gibi gemilerin tespitini iyileştirebilir. Ayrıca, deniz yüzeyindeki rüzgar yönü ve hızına ilişkin bilgiler sunarak okyanus akıntılarının izlenmesi ve fırtına dalgalandırmalarının tahmin edilmesi gibi oşinografik çalışmalara katkı sağlar. Bunun yanı sıra, mahsul izleme ve afet müdahaleleri gibi kara uygulamalarında da değerlendirilmektedir. Sentinel-1'in VH verilerinin geniş kullanım alanı, onu çok yönlü ve değerli bir veri kaynağı haline getirmektedir.

Tablo 1. Sentinel-1 Uydusunun Teknik Özellikleri.

Parametre	Teknik Özellik
Frekans	C-band (5.405 GHz)
Sıklık	Çift polarizasyon (VV ve VH)
Mekansal Çözünürlük	5 m (VV polarizasyon) / 20 m (VH polarizasyon)
Tarama Genişliği	400 km'ye kadar
Yeniden Ziyaret Süresi	6 - 12 gün
Yörünge	Güneşle eşzamanlı kutupsal yörünge
Görev Süresi	7 yıl için planlanmıştır (uzatılabilir)

2.3. Yöntem

Uydu görüntülerinden gemi tespiti ve takibi, deniz gözetimi, gemi trafiği yönetimi ve çevresel izleme açısından kritik bir öneme sahiptir. Sentetik Açıkkılık Radar (SAR) görüntüleri, gece ve olumsuz hava koşullarında da çalışabilmesi sayesinde gemi tespiti için etkili bir araç olarak öne çıkmaktadır. Son yıllarda, derin öğrenme tabanlı algoritmalar nesne tespitinde büyük ilerlemeler sağlamıştır.

SARfish, SAR görüntülerini ve Faster R-CNN algoritmasını kullanarak gemi algılama işlemini gerçekleştiren açık kaynaklı bir uygulamadır. SARfish algoritması, SAR görüntülerini önce gürültü ve benekleri gidermek için ön işler, ardından derin sinir ağları yardımıyla görüntüdeki gemileri tespit eder ve sınıflandırır. Yapılan testlerde, SARfish algoritmasının %92,9 hassasiyet (AP) ile yüksek doğruluk sağladığı belirlenmiştir. Ayrıca, zaman içindeki gemi hareketlerini izleyerek yörünge bilgileri

de sunmaktadır. Kullanıcılar, SARfish veri havuzu aracılığıyla gemi tespit sonuçlarını analiz edebilir ve görselleştirebilir.

Faster R-CNN algoritması, nesne tespiti için gelişmiş bir derin öğrenme modelidir. Konvolüsyonel sinir ağı (CNN) kullanarak özellik haritaları oluşturur ve Bölge Öneri Ağı (RPN) yardımıyla potansiyel nesne bölgelerini belirler. Ardından, İlgi Bölgesi (RoI) havuzlama işlemi ile bu bölgeler sınıflandırılarak nesne koordinatları hassas bir şekilde ayarlanır. Faster R-CNN, bölge önerme ve sınıflandırma işlemlerini tek bir birleşik çerçeveye entegre ederek yüksek doğrulukta nesne tespiti gerçekleştirir.

SARfish algoritması, SAR görüntülerinden gemi tespiti ve takibi için güçlü, esnek ve özelleştirilebilir bir çözüm sunmaktadır. Deniz güvenliği, gemi trafiği yönetimi ve çevresel izleme gibi birçok alanda kullanılabilir. Açık kaynak olması, araştırmacılar ve uygulayıcılar için özelleştirme ve geliştirme imkânı sağlayarak denizcilik alanında önemli bir katkı sunmaktadır.

3. Bulgular

Önerilen gemi tespit algoritması, Faster R-CNN mimarisine dayanarak Sentinel-1 VH SAR görüntülerine uygulanmış ve farklı boyutlardaki gemileri yüksek doğrulukla tespit edebilmiştir. Algoritma, konvolüsyonel sinir ağları ve bölge öneri ağlarının birleşimiyle çalışarak gemileri tanımlamış, tespit edilen gemilerin konumları bir harita üzerinde görselleştirilmiştir.



Şekil 2. Önerilen gemi tespit algoritması kullanılarak Sentinel-1 VH SAR görüntülerinden çıkarılan gemiler (kırmızı ile işaretlendi).

Test veri kümesi üzerinde algoritma, %86,11 genel doğruluk oranı elde etmiştir. Küçük balıkçı teknelerinden büyük kargo gemilerine kadar farklı türlerdeki gemiler başarıyla tespit edilmiş olup yanlış pozitif oranı düşük çıkmıştır. Kesinlik (precision) ve geri çağırma (recall) değerleri sırasıyla %84,54 ve %89,03 olarak hesaplanmış, bu da yanlış pozitif ve yanlış negatif hatalar arasında dengeli bir performans sergilendiğini göstermektedir.

Tablo 2. Önerilen gemi tespit algoritmasının doğruluk sonuçları.

Yöntem	Doğruluk (%)
SARfish	86.11

Genel olarak, Faster R-CNN tabanlı algoritma, SAR görüntülerinde gemi tespiti için etkinliğini kanıtlamış ve gerçek zamanlı deniz gözetleme sistemlerine entegre edilebilecek potansiyel bir çözüm olarak öne çıkmıştır.

4. Sonuçlar

Bu çalışma, Sentinel-1 VH SAR görüntüleri kullanarak Faster R-CNN mimarisine dayalı açık kaynaklı bir gemi algılama algoritmasının potansiyelini araştırarak gemi tespiti alanındaki literatür boşluğunu gidermeyi amaçlamaktadır. Geleneksel yöntemlerin optik görüntülere ve çevresel koşullara bağımlı olmasının getirdiği sınırlamaları aşmak için derin öğrenme teknikleri ve SAR görüntüleri kullanılmıştır.

Önerilen algoritma, yüksek doğruluk oranı ve düşük yanlış pozitif oranı ile gerçek dünya denizcilik uygulamaları için uygun bir çözüm sunmaktadır. Farklı boyut ve türdeki gemileri başarılı bir şekilde tespit edebilmesi, algoritmanın çok yönlü ve çeşitli denizcilik senaryolarına uyaranabilir olduğunu göstermektedir.

Çalışma, SAR görüntülerinin derin öğrenme algoritmalarıyla birleştirilmesinin etkinliğini vurgulamakta ve bu alandaki gelecekteki araştırmalara yön vermektedir. Gemi tespiti ve deniz gözetimi alanındaki gelişmelere katkıda bulunarak, deniz emniyeti, güvenliği ve çevrenin korunması açısından güvenilir algoritmalar geliştirmenin önemine dikkat çekmektedir. Aynı zamanda, bu çalışma sadece mevcut literatüre katkı sağlamakla kalmayıp, SAR görüntülerini ve derin öğrenme teknikleri ile gemi tespiti konusunda yeni araştırmaları teşvik etmektedir.